

**CEFET/RJ - CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA**

**Previsão de Receitas de Multas de Trânsito do
Município do Rio de Janeiro**

Carlos Henrique de Oliveira Pereira

Prof. Orientador:

Eduardo Soares Ogasawara, D.Sc.

Boris Marinho Ramos Silva Araujo

Rio de Janeiro

26-06-2026

**CEFET/RJ - CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA**

Previsão de Receitas de Multas de Trânsito do Município do Rio de Janeiro

Carlos Henrique de Oliveira Pereira

Projeto final apresentado em cumprimento às
normas do Departamento de Educação
Superior do Centro Federal de Educação
Tecnológica Celso Suckow da Fonseca,
CEFET/RJ, como parte dos requisitos para
obtenção do título de Bacharel em Ciência da
Computação.

Prof. Orientador:

Eduardo Soares Ogasawara, D.Sc.

Boris Marinho Ramos Silva Araujo

Rio de Janeiro

26-06-2026

Obtenha a ficha catalográfica junto a biblioteca.
Substitua o arquivo ficha.pdf pela versão obtida lá.

DEDICATÓRIA

Dedico este trabalho:

Aos meus familiares, pelo apoio incondicional
e pela paciência nos momentos desafiadores,
que são pilares fundamentais ao longo da
minha trajetória.

Aos meus professores e orientadores, pela
transmissão de conhecimento, pelo incentivo
constante e pela orientação que possibilita a
realização desta conquista.

Aos meus amigos, pelas risadas que trazem
leveza, pelas palavras de incentivo nos
momentos de dúvida e pela companhia
presente nos instantes de descontração,
essenciais para manter o equilíbrio e a
motivação.

Esta conquista também é fruto do apoio de
cada um de vocês.

Com gratidão,
Carlos Henrique de Oliveira Pereira.

AGRADECIMENTOS

Agradece-se à CAPES, CNPq e FAPERJ pelo financiamento parcial desta pesquisa.

RESUMO

O financiamento de investimentos realizados por órgãos de mobilidade urbana é crítico, pois, mesmo gerando impactos positivos com melhorias em sinalizações e estruturas viárias, pode prejudicar a instituição quando feito sem planejamento adequado. Parte das receitas dessas instituições provém de multas de trânsito, o que torna relevante o estudo de técnicas de previsão de receitas futuras para um planejamento mais preciso. Neste estudo, são realizados experimentos de previsão em séries temporais com alguns modelos de aprendizado de máquina, disponibilizados na biblioteca TSPrediT. O objetivo principal é investigar o desempenho desses modelos na previsão de receitas do município do Rio de Janeiro, com base nas métricas de erro R^2 , SMAPE e MSE. Os modelos de aprendizado de máquina mostraram-se relevantes na previsão de receitas, tendo como destaque o modelo MLP que obteve um valor de R^2 de 60.26%.

Palavras-chaves: Séries temporais; Agregação temporal; Aprendizado de Máquina; Previsão de receitas; Multas de trânsito.

ABSTRACT

Financing investments carried out by urban mobility agencies is critical because, despite generating positive impacts through improvements in signaling and road infrastructure, it can jeopardize the institution when conducted without proper planning. Since a portion of these institutions' revenue stems from traffic fines, the study of techniques for forecasting future revenue becomes essential for more accurate planning. In this study, time series forecasting experiments are performed using various machine learning models available in the TSPrediT library. The primary objective is to investigate the performance of these models in forecasting revenue for the municipality of Rio de Janeiro, based on the error metrics R^2 , SMAPE, and MSE. Machine learning models proved to be relevant for revenue forecasting, with the MLP model standing out by achieving an R^2 value of 60.26%.

Keywords: Time series; Temporal aggregation; Machine Learning; Revenue forecasting; Traffic fines.

Sumário

1	Introdução	1
2	Fundamentação teórica	3
2.1	Séries Temporais	3
2.2	Indicadores de desempenho	4
2.3	Critério AIC	6
2.4	Arima	6
2.5	Média Móvel Simples	7
2.6	Agregação Temporal	7
2.7	Modelos de Aprendizado de Máquina	8
3	Trabalhos Relacionados	10
4	Método	12
4.1	Base de dados	12
4.2	Implementação	12
5	Resultados	17
6	Conclusão	24
	Referências	25

Lista de Figuras

FIGURA 1:	Exemplo de decomposição	4
FIGURA 2:	Exemplo de série temporal estacionária. A linha tracejada indica a média da série temporal.	5
FIGURA 3:	Suavização da série temporal por média móvel. (a) Suavização com $n = 3$ dias; (b) Suavização com $n = 7$ dias; (c) Suavização com $n = 30$ dias. Ao fundo de cada exemplo, em cinza, está plotada a série temporal sem suavização.	8
FIGURA 4:	Série temporal sinalizando o início com receita reduzida devido à limitação de dados. A linha tracejada indica o limite do recorte da série.	13
FIGURA 5:	Previsão da receita no período de 12 meses com o modelo Auto ARIMA.	18
FIGURA 6:	Previsão da receita no período de 12 meses com o modelo MLP - fold 1.	19
FIGURA 7:	Previsão da receita no período de 12 meses com o modelo MLP - fold 2.	19
FIGURA 8:	Previsão da receita no período de 12 meses com o modelo MLP - fold 3.	20
FIGURA 9:	Previsão da receita no período de 12 meses com o modelo MLP - fold 4.	20
FIGURA 10:	Previsão da receita no período de 12 meses com o modelo KNN - fold 1.	21
FIGURA 11:	Previsão da receita no período de 12 meses com o modelo KNN - fold 2.	21
FIGURA 12:	Previsão da receita no período de 12 meses com o modelo ELM - fold 1.	22
FIGURA 13:	Previsão da receita no período de 12 meses com o modelo ELM - fold 2.	22

FIGURA 14:	Previsão da receita no período de 12 meses com o modelo ELM - fold 3.	23
FIGURA 15:	Previsão da receita no período de 12 meses com o modelo ELM - fold 4.	23

Lista de Tabelas

TABELA 2:	Hiperparâmetros dos modelos	16
TABELA 3:	Resultados obtidos na experimentação ranqueados em ordem crescente de R^2 .	18

Acrônimos

R^2	R-Squared.
ARIMA	AutoRegressive Integrated Moving Average.
ARMA	AutoRegressive Moving Average.
KNN	K-Nearest Neighbour.
LDO	Lei de Diretrizes Orçamentárias.
LOA	Lei Orçamentária Anual.
ML	Aprendizado de Máquina.
MLP	Multi Layer Perceptron.
MMS	Média Móvel Simples.
MSE	Mean Squared Error.
PPA	Plano Plurianual.
SETTRAN	Secretaria Municipal de Trânsito e Transportes.
SMAPE	Symmetric Mean Absolute Percentage Error.
SOF	Secretaria de Orçamento Federal.

Capítulo 1

Introdução

O modelo orçamentário brasileiro vigente foi consolidado com a Constituição Federal de 1988 e tem como objetivo o planejamento e o gerenciamento das finanças públicas do país [Deputados, 2025]. Ele é composto por três elementos-base: o *Plano Plurianual (PPA)*, a *Lei de Diretrizes Orçamentárias (LDO)* e a *Lei Orçamentária Anual (LOA)*. O *PPA* estabelece as diretrizes, os objetivos e as metas de médio prazo da administração pública, orientando, de forma conjunta, a *LDO* e a *LOA*. A *LDO* define os parâmetros necessários para a alocação de recursos no orçamento anual, assegurando a realização das metas e dos objetivos contemplados no *PPA*. A *LOA* permite estimar receitas e fixar despesas, viabilizando análises sobre a origem e a destinação dos recursos públicos. Dessa forma, a legislação brasileira orienta os órgãos públicos a cumprirem as metas e os objetivos estabelecidos.

O orçamento é um documento central da política que viabiliza a execução de programas governamentais destinados a beneficiar a sociedade e promover melhorias no país [Speeden and Perez, 2019]. O município é o ente subnacional mais capacitado para solucionar problemas locais, pois possui o conhecimento mais preciso sobre suas prioridades e os impactos das demandas sociais de sua população [Louzano et al., 2019]. No contexto da mobilidade urbana, o orçamento é planejado com foco em melhorias nas vias públicas, na sinalização viária, na implementação de novas rotas de trânsito, no subsídio tarifário ao transporte público, entre outras intervenções voltadas à circulação, à segurança viária e à promoção da mobilidade urbana. A arrecadação de multas de trânsito é uma fonte de receita substancial para o setor, somando mais de 304 milhões no Rio de Janeiro em 2024, de acordo com dados da prefeitura [Lima Neto, 2025].

Um planejamento orçamentário adequado é essencial para viabilizar o financiamento dos serviços e dos programas públicos [Nascimento and Boente, 2022]. A maior precisão na previsão das receitas públicas traz benefícios para a gestão da mobilidade urbana, pois contribui para a estabilidade do financiamento e reduz o risco de descontinuidade das ações planejadas [da Costa, 2017]. Previsões mais precisas de receita favorecem a execução orçamentária e aumentam a estabilidade no financiamento das despesas previstas na *LOA*.

Este trabalho experimenta e avalia a possibilidade de utilização de um modelo de aprendizado de máquina capaz de prever receitas de multas de trânsito em uma janela de um ano, aplicando agregação temporal para reduzir os ruídos e melhorar o desempenho preditivo dos modelos na previsão de receitas de multas de trânsito do município do Rio de Janeiro. O estudo considera horizontes de previsão de um ano, em função da aplicabilidade prática no contexto do planejamento orçamentário municipal. Assim, os experimentos são executados com a transformação da série temporal. A série apresenta mudanças abruptas de comportamento no período entre 2020 e 2022, possivelmente explicadas por alterações legislativas durante a pandemia de COVID-19, porém não se aplicam técnicas de modelagem de rupturas estruturais devido à baixa frequência do evento e à dificuldade de parametrização adequada.

Quanto às métricas de avaliação dos resultados obtidos, observa-se que a série temporal com suavização de $k = 1$, ou seja, a série sem qualquer transformação, apresenta valor de *R-Squared* (R^2) mais elevado em comparação com as demais séries. Também se verifica que, à medida que o grau de suavização aumenta, o valor do *Symmetric Mean Absolute Percentage Error* (SMAPE) diminui. Não se obtêm conclusões quanto à métrica *Mean Squared Error* (MSE).

Embora diversas pesquisas apresentem bons resultados ao prever receitas públicas com modelos *AutoRegressive Integrated Moving Average* (ARIMA), o conjunto de dados utilizado apresenta uma variação atípica que pode impactar negativamente o desempenho do modelo. Apesar da quebra estrutural da série, é possível que existam métodos mais eficazes para essa tarefa. Modelos mais sofisticados, como Redes Neurais, Long Short-Term Memory (LSTM) e k-Nearest Neighbors(KNN), podem ser vantajosos. Portanto, recomenda-se o estudo de novos métodos para previsão de receitas, especificamente para esta série temporal.

Além da introdução, este trabalho está organizado em mais cinco capítulos. O Capítulo 2 apresenta a fundamentação teórica. O Capítulo 3 apresenta os trabalhos relacionados. O Capítulo 4 descreve o método. No Capítulo 5, são mostrados os resultados. E, por fim, no Capítulo 6 é apresentada a conclusão.

Capítulo 2

Fundamentação teórica

Este capítulo apresenta os conceitos essenciais para o entendimento deste trabalho. A Seção 2.1 resume os elementos fundamentais de uma série temporal. A Seção 2.2 descreve os indicadores de desempenho, importantes para a compreensão e interpretação dos resultados preliminares. A Seção 2.4 explica o *ARIMA*, um modelo de previsão amplamente utilizado em séries temporais. A Seção 2.5 resume a *Média Móvel Simples (MMS)*, uma técnica utilizada para suavizar séries temporais. A Seção 2.6 apresenta a agregação temporal, uma técnica que transforma a série a partir do agrupamento de observações próximas.

2.1 Séries Temporais

Uma série temporal é uma sequência $(x_1, x_2, \dots, x_n)$ separada por um intervalo fixo de tempo (por exemplo, segundos, horas ou dias). Esses dados podem ser agregados em intervalos maiores, como quinzenas, semanas ou trimestres [Gujarati, 2003]. As séries temporais podem ser univariadas, quando há observações de apenas uma variável, ou multivariadas, quando há observações de duas ou mais variáveis. No caso multivariado, podem ser exploradas relações entre as variáveis para aumentar o desempenho do modelo [Silvestrini and Veredas, 2008].

É possível decompor uma série temporal em três componentes: tendência, sazonalidade e resíduo. Cada componente contém informações relevantes sobre o comportamento da série, auxiliando em análises mais precisas e na identificação de padrões [Ogasawara et al., 2025c].

A tendência é a componente que indica o movimento da série temporal ao longo do tempo. Ela revela se a série é crescente, decrescente ou estável em determinado intervalo [Ogasawara et al., 2025c]. Um exemplo de tendência crescente é o uso de inteligências artificiais generativas nos últimos anos.

A sazonalidade representa padrões que se repetem em intervalos regulares, como dias, meses ou anos. Esses padrões são frequentemente observados em setores de vendas, por exemplo. O aumento da demanda por presentes no período natalino é um exemplo característico dessa componente [Ogasawara et al., 2025c; Zellner, 1978].

O resíduo refere-se ao que permanece após a remoção da tendência e da sazonalidade. Trata-se das variações não explicadas pelos demais componentes, mas que ainda compõem parte relevante das observações. A decomposição auxilia na análise e na compreensão da estrutura da série temporal, assegurando que as variações desordenadas permaneçam apenas nos resíduos [Ogasawara et al., 2025c].

A série é dita estacionária quando sua tendência e sazonalidade são nulas. Isso significa que seus valores não estão correlacionados com o tempo e que sua média e variância são constantes. Esse comportamento também pode ser denominado ruído branco [Hyndman and Athanasopoulos, 2018; Sato, 2013].

Como o modelo *ARIMA* requer estacionaridade, procedimentos como diferenciação e suavização são frequentemente aplicados para eliminar a tendência e a sazonalidade, estabilizando a média e a variância da série [Sato, 2013].




Figura 1: Exemplo de decomposição

2.2 Indicadores de desempenho

Em todo modelo preditivo, é necessário analisar seu desempenho e compará-lo com outros modelos para obter resultados confiáveis [Hyndman and Athanasopoulos, 2018]. Há diversos métodos para avaliar o desempenho desses modelos. Neste trabalho, utilizam-se três métricas: *MSE*, *SMAPE* e o Coeficiente de Determinação (R^2).




Figura 2: Exemplo de série temporal estacionária. A linha tracejada indica a média da série temporal.

Para as equações a seguir, n é o número de previsões, y_t é a observação original, $\hat{y}_t$ é a previsão da série e t representa o tempo.

Representado pela fórmula 2.1, o *Symmetric Mean Absolute Percentage Error (SMAPE)* é uma métrica baseada na porcentagem do erro. Essa métrica é útil para valores com grande variação de escala. Seu resultado pode variar de 0, quando não há erro, até $+\infty$, indicando o pior caso nas previsões [Ogasawara et al., 2025c].

O *Mean Squared Error (MSE)* é uma métrica calculada na mesma escala dos dados. Como mostrado na fórmula 2.2, é sensível a outliers devido à operação de elevação ao quadrado [Chen et al., 2017]. Pode variar de 0, em caso de erro nulo, até $+\infty$, sendo que valores mais altos indicam pior desempenho.

Definido pela fórmula 2.3, o *R-Squared (R^2)* é uma métrica que mede a proporção da variabilidade da variável dependente explicada pelo modelo [Chicco et al., 2021]. Em outras palavras, avalia o grau de ajuste entre os dados previstos e os dados observados. Pode variar de $-\infty$ a 1, sendo que valores próximos de 1 indicam bom ajuste. Quando $R^2 = 1$, o modelo representa perfeitamente os dados reais. Valores positivos indicam ajuste satisfatório, enquanto valores negativos indicam ajuste inadequado.

$$\text{SMAPE} = \frac{100}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{(|y_t| + |\hat{y}_t|)/2} \quad (2.1)$$

$$\text{MSE} = \frac{1}{n} \sum_{t=1}^n (\hat{y}_t - y_t)^2 \quad (2.2)$$

$$R^2 = 1 - \frac{\sum_{t=1}^n (\hat{y}_t - y_t)^2}{\sum_{t=1}^n (\bar{y} - y_t)^2} \quad (2.3)$$

Enquanto o *MSE* mede o desempenho de forma relativa e dependente da escala, penalizando fortemente outliers, o *SMAPE*, por ser percentual, apresenta maior robustez frente a variações de escala, tornando-se sensível em séries com alta dispersão. A análise combinada de *SMAPE*, *MSE* e R^2 permite avaliar a acurácia, a variabilidade e o grau de explicação da previsão, sendo necessária para a interpretação crítica do desempenho preditivo [Hyndman and Athanasopoulos, 2018].

2.3 Critério AIC

O Critério de Informação de Akaike, abreviado como AIC, é uma métrica estatística utilizada para selecionar modelos que tentam equilibrar a simplicidade e a explicabilidade dos dados. Proposto por Hirotugu Akaike em 1974, o critério baseia-se na teoria da informação e na busca pela minimização da perda de informação ao representar uma série real por meio de uma equação matemática. A base teórica do AIC é a Divergência de Kullback-Leibler, que mede a diferença entre o modelo candidato proposto e o modelo verdadeiro. O AIC funciona como uma estimativa dessa diferença; portanto, quanto menor o valor do AIC, mais próximo o modelo candidato está de representar a realidade sem perda excessiva de informação [Vrieze, 2012].

Na equação 2.4, o L representa a máxima verossimilhança do modelo, indicando o quão bem o modelo explica os dados observados, e k é o número de parâmetros estimados. O termo $2k$ atua como uma penalidade: quanto mais complexo o modelo, maior será o valor do AIC, exceto se esse aumento de complexidade resultar em um ganho significativo de ajuste.

$$\text{AIC} = -2\ln(L) + 2k \quad (2.4)$$

2.4 Arima

Denominado extensivamente como *AutoRegressive Integrated Moving Average*, o *ARIMA* é um modelo autorregressivo de previsão amplamente utilizado desde sua criação, em 1970, por George Box e Gwilym Jenkins. Seu funcionamento baseia-se na identificação de padrões nos dados para a obtenção de operadores que, combinados, formam uma equação linear represen-

tativa da série temporal [Box and Jenkins, 1970]. No modelo $ARIMA(p, d, q)$, p representa o grau da parte autorregressiva, d o grau da diferenciação e q o grau da parte de média móvel [Sato, 2013; Hyndman and Khandakar, 2008]. Dependendo dos valores desses parâmetros, o modelo apresenta configurações específicas. Um exemplo é o $ARIMA(0, 1, 0)$, conhecido como *Random Walk*. O *Auto ARIMA* é uma função que determina automaticamente os valores de p , d e q com base no melhor valor do AIC, critério utilizado para avaliar a qualidade de modelos estatísticos [Hyndman and Khandakar, 2008].

Esse modelo é utilizado preferencialmente com séries estacionárias. Quando a série não é estacionária, aplica-se a diferenciação, que consiste no cálculo da diferença entre observações consecutivas. Também é possível aplicar a diferenciação sazonal, calculada em intervalos equivalentes ao ciclo de sazonalidade. A aplicação da diferenciação estabiliza a média da série e reduz ou elimina a tendência e a sazonalidade [Hyndman and Athanasopoulos, 2018].

2.5 Média Móvel Simples

A *Média Móvel Simples (MMS)* é uma técnica utilizada para suavizar séries temporais. Dado um número n , calcula-se a média aritmética das n observações vizinhas a uma observação x_i [Hansun, 2013]. Quanto maior o valor de n , maior a suavização e menor a preservação da informação original da série. A suavização por média móvel visa reduzir a variabilidade local da série, minimizando a influência de ruídos e outliers na estimação dos parâmetros do modelo.

Representado pela fórmula 2.5, MMS_t é o valor da série de *MMS* suavizada para a série X no tempo t . O parâmetro n indica a janela da média móvel. Quanto maior a janela, mais suavizada é a série. X_{t-i} é o valor da série X no tempo $t - i$, em que i itera sobre o tamanho da janela.

$$MMS_t = \frac{1}{n} \sum_{i=0}^{n-1} X_{t-i} \quad (2.5)$$

A Figura 3 apresenta a aplicação de diferentes graus de suavização em uma série. Observa-se que o aumento do grau de suavização reduz as oscilações da série, mantendo a média local.

2.6 Agregação Temporal

Uma técnica amplamente utilizada na previsão de séries temporais é a agregação temporal das observações. Transformar a série por meio de agregação temporal permite analisá-la em outros agrupamentos de tempo. Podem ser realizados agrupamentos contendo observações se-



Figura 3: Suavização da série temporal por média móvel. (a) Suavização com $n = 3$ dias; (b) Suavização com $n = 7$ dias; (c) Suavização com $n = 30$ dias. Ao fundo de cada exemplo, em cinza, está plotada a série temporal sem suavização.

manais, quinzenais ou mensais, por exemplo [Salles et al., 2016]. Estatisticamente falando, a agregação temporal atua como um mecanismo de suavização que reduz a variância dos erros de alta frequência. Ao agregar as observações, componentes sazonais de curto prazo e irregularidades tendem a se compensar, destacando os componentes de tendência e ciclo da série. É evidenciado que, quanto maior o nível de agregação temporal, mais fácil se torna a previsão de uma série temporal, apesar de ser necessária uma quantidade mínima para compor uma série agregada [Rostami-Tabar et al., 2013; Silvestrini and Veredas, 2008].

Dada uma série temporal x_t , com $t = 1, 2, \dots, n$ representando os dias sequenciais, sua versão agregada X_T , com janela de agregação de tamanho m , é obtida pela fórmula 2.6, em que T indica a sequência de observações da série agregada.

$$X_T = \sum_{t=(T-1)m+1}^{tm} x_t, \quad \text{para } T = 1, 2, \dots, \left\lfloor \frac{n}{m} \right\rfloor \quad (2.6)$$

2.7 Modelos de Aprendizado de Máquina

Diferente de modelos estatísticos tradicionais, modelos de *Aprendizado de Máquina (ML)* em séries temporais funcionam como aproximadores universais de uma função contínua, tendo como base observações passadas. Desde que se tenha dados suficientes como base, esses modelos são capazes de aprender com esses dados e utilizar seu conhecimento para prever os dados seguintes. Dentre os modelos de *ML*, os mais conhecidos são modelos de Redes Neurais que imitam o funcionamento do cérebro humano, conectando os neurônios por meio de sinapses,

as quais possuem pesos associados que representam a relevância de cada conexão [Ogasawara et al., 2025c].

Embora, hoje em dia, os modelos sejam bastante difundidos, eles são muito dependentes de configurações internas para que seu funcionamento seja adequado aos dados quais estão submetidos. Para ajustar essas configurações é preciso ter um nível de conhecimento um pouco maturado [Koutsoukas et al., 2017]. Essas configurações são chamadas de hiperparâmetros quando definidas compõem uma instância única do modelo. Os hiperparâmetros podem estar oLP, ou ao número de núcleos de agrupamento, no caso do KNN, entre outros exemplos [Ogasawara et al., 2025c].

Hiperparâmetros são variáveis fundamentais que afetam a maneira como os modelos descobrem os padrões de um conjunto de dados. A sua seleção impacta diretamente no desempenho de um modelo. Uma técnica popularmente conhecida e utilizada para otimização de hiperparâmetros é a Busca em Grade (Grid Search). Esta técnica busca testar diversas combinações de hiperparâmetros para avaliar e escolher o um modelo mais eficiente [Monica and Agrawal, 2024; Ramamohan et al., 2024].

Capítulo 3

Trabalhos Relacionados

A previsão de séries temporais tem sido amplamente estudada e aplicada em diferentes domínios, como finanças, saúde, indústria e gestão pública. Diversas abordagens foram propostas, desde modelos estatísticos tradicionais até técnicas mais recentes baseadas em aprendizado de máquina.

A revisão sistemática considerou publicações anteriores a 2024, com foco na previsão de receitas públicas por meio de séries temporais, utilizando os termos "previsão de receitas de multas de trânsito; previsão orçamentária" nas bases Scopus e Google Scholar. Diversos resultados foram obtidos. Observou-se que a previsão de receitas públicas é um tema bastante explorado, sobretudo em áreas periféricas, como previsão de ICMS, de infrações de trânsito e de IPVA, entre outras. Apesar de se tratar de um tema relevante no contexto do orçamento municipal, verifica-se uma baixa quantidade de estudos voltados à previsão de receitas de multas de trânsito. Apenas dois estudos com temas semelhantes foram encontrados, dos quais somente um apresenta relação direta com o objetivo deste trabalho.

PUCRJ [2024] realiza previsões com a mesma série temporal de receitas de multas de trânsito, porém, com um recorte do início de 2019 ao final de 2023. Eles adotam, na metodologia, uma abordagem que tenta contornar impactos causados pela COVID-19. Para a previsão final, utilizaram o modelo SARIMA(1,1,1)-(1,1,12), que contém uma componente sazonal de 12 meses. Neste estudo não foram obtidos resultados relevantes que pudessem ser utilizados para prever efetivamente e período desejado. O ponto que mais se destaca é que os autores não realizaram experimentos com modelos mais robustos de aprendizado de máquina como MLP, KNN e ELM.

Da Silva et al. [2018], visando aumentar a efetividade da previsão de receitas do município de Uberlândia, realiza um estudo comparativo entre a previsão de receitas feita pela *Secretaria Municipal de Trânsito e Transportes (SETTRAN)*, com base no modelo disponibilizado pela *Secretaria de Orçamento Federal (SOF)*, e a previsão realizada com o modelo *AutoRegressive Moving Average (ARMA)*, no período de 2002 a 2017. O estudo mostra que o modelo ARMA utilizado foi mais preciso, com percentual médio de erros de 17,19%, frente a 24,47% do mo-

delo da *SOF*. Também é demonstrado que o modelo *ARMA* apresentou erro médio inferior em 9 dos 16 anos analisados. Os autores não realizam qualquer tipo de transformação na série original utilizada.

Em um contexto similar, Naibert [2021] compara o desempenho da previsão de receitas de diversos municípios do estado do Rio Grande do Sul entre os anos de 2008 e 2019. O autor realiza um estudo comparativo entre o modelo da *SOF* e o *ARIMA*. Os resultados indicam que o modelo da *SOF* é mais suscetível a erros, enquanto o *ARIMA* apresenta desempenho superior em 83% dos casos analisados. Observa-se, entretanto, que essa dominância não é uniforme. Por exemplo, no município de Porto Alegre, o modelo da *SOF* foi superior em 11 dos 12 casos testados. Embora o estudo indique a superioridade do *ARIMA* em relação ao modelo da *SOF*, as séries utilizadas estão inseridas em contextos distintos.

De modo geral, a literatura revisada aponta um déficit na capacidade preditiva do modelo da *SOF*, que apresenta desempenho inferior ao modelo *ARIMA*. A previsão de receitas públicas ainda carece de soluções eficazes, o que contribui para tornar o planejamento orçamentário incerto e desatualizado. A comparação com estudos anteriores é limitada por diferenças estruturais entre as séries, particularmente no período pandêmico, que introduz quebras de padrão não modeladas nos trabalhos revisados. Diferentemente dos estudos mencionados, este trabalho explora a transformação da série temporal por suavização e agregação como mecanismo de mitigação de ruídos e de melhoria da acurácia preditiva.

Capítulo 4

Método

A metodologia adotada neste trabalho propõe a realização de previsões para séries temporais de arrecadação de multas de trânsito no município do Rio de Janeiro. Ao final, os resultados obtidos são utilizados para comparar o desempenho das instâncias dos modelos. As previsões são realizadas no ambiente *RStudio 2024.12.0*, com auxílio das bibliotecas *TSPredit* e *Daltoolbox* [Ogasawara et al., 2025a,b]. A seguir, apresenta-se a Seção 4.1, que fornece informações sobre o conjunto de dados. A Seção 4.2 descreve as etapas de execução do trabalho. Ressalta-se que os dados utilizados referem-se exclusivamente a registros históricos de pagamentos de multas de trânsito decorrentes de multas já lavradas pelo município, não estando relacionados à definição, alteração ou proposição de políticas de multa ou de fiscalização. A finalidade da pesquisa restringe-se à análise estatística da série temporal dessas receitas, com foco na melhoria da acurácia preditiva para fins de planejamento orçamentário, e não à formulação de medidas voltadas ao aumento da arrecadação.

4.1 Base de dados

¹ Disponibilizada pela Secretaria Municipal de Transportes do Rio de Janeiro [2025] por meio do portal de dados abertos *Data.Rio*, a base de dados é composta por registros de infrações de trânsito no período de 2014 a 2025, contendo informações como data da ocorrência, data de pagamento, valor da infração, tipo de veículo, entre outras. Os dados estão ordenados pela data de pagamento. Neste trabalho, utilizam-se apenas os atributos *Data de Pagamento*, *Valor Pago* e *Data de Ocorrência*.

4.2 Implementação

Na etapa inicial da implementação, ocorre o carregamento dos dados. Em seguida, realiza-se o pré-processamento, que inclui o tratamento de valores inválidos, conversões e a definição dos limites temporais da série. Nessa etapa, também são removidas as multas sem valor pago

registrado, por impossibilitarem a consolidação da série de receitas efetivas, sendo tratadas como dados censurados. Como representado na Figura ??, a série temporal de receitas diárias apresenta distorções significativas em seu início, com baixo volume de receitas em comparação ao restante da série, devido a limitações no registro das multas. Como a janela de obtenção dos dados é finita, principalmente no início da série, o cálculo de A_{x_i} torna-se incerto, pois há multas pagas que não constam no conjunto disponibilizado por terem sido registradas em período anterior ao início da base. Para mitigar esse problema, realiza-se um recorte, excluindo os dados anteriores a 2016.




Figura 4: Série temporal sinalizando o início com receita reduzida devido à limitação de dados. A linha tracejada indica o limite do recorte da série.

Após o pré-processamento, ocorre a criação da série efetivamente utilizada para a modelagem. As multas são organizadas com agregação mensal das receitas, de forma que todas as multas pagas em um mesmo mês sejam somadas, gerando a série temporal de receitas mensais z_i . Para um mês específico x_i no período analisado (i -ésimo mês), o valor da receita mensal z_i é calculado pela soma dos valores individuais y_k de todas as n multas que compõem o conjunto A_{x_i} (todas as multas pagas nesse mês). A equação da série é definida pela Equação 4.1:

$$z_i = \sum_{k=1}^n y_k \quad \text{para cada } a_k \in A_{x_i} \quad (4.1)$$

Posteriormente à criação da série de receitas mensais, obtém-se um dataframe que será armazenado para servir como input na etapa seguinte. O dataframe contém apenas o valor arrecadado no mês, e constam exatamente 120 meses de arrecadação, do início de 2016 ao final de 2024.

Na implementação, é utilizado e adaptado um framework de experimentação exaustiva que

emprega a técnica de *Grid Search* para otimização de hiperparâmetros. Seu propósito central é iterar sobre combinações de um conjunto pré-definido de hiperparâmetros, treinar os modelos com essas combinações, em seguida testar os modelos e registrar suas métricas de avaliação. É importante mencionar que, embora configurações como métodos de normalização, tamanho da janela deslizante (*sliding window*) e tamanho das janelas de treino e teste sejam padronizadas para todos os experimentos, os *ranges* (parâmetros particulares de cada modelo) dos principais hiperparâmetros são únicos para cada modelo. Por exemplo, o modelo *Multi Layer Perceptron* (*MLP*) varia em *input_size* e *size* (camadas internas), enquanto o *K-Nearest Neighbour* (*KNN*) varia no número *k* de vizinhos próximos. A seguir, apresenta-se um pseudocódigo que representa o processo realizado pelo framework.

A função *run_ml* é utilizada para iniciar o processo. Ela é responsável por armazenar todos os casos de combinações de hiperparâmetros possíveis e repassar para as funções intermediárias que irão treinar e testar o modelo com janelas deslizantes variáveis. Para treinar os casos dos modelos, avalia-se e mensura-se qual caso obtém o melhor ajuste possível, com base na métrica de erro. Quanto menor o erro, melhor o desempenho do modelo. No teste, o modelo é testado em um período sequencial de 12 meses (um ano à frente). Por fim, a lista com todos os modelos é retornada e ordenada para identificar o melhor desempenho de cada modelo.

Algorithm 1 *run_ml*

```

1: df ← carregar_dataframe()
2: ts ← obter_serie(df)
3: t_teste ← 12
4: t_treino ← obter_tamanho_serie(ts) - tamanho_teste
5: combinacoes ← obter_combinacoes(preprocs, hiperparametros)
6: resultados_gerais ← nova_lista()
7: for caso em combinações do
8:   modelo_otimizado ← treinar_ml(ts[1:t_treino], caso, t_janela)
9:   resultado_teste ← testar_ml(modelo_otimizado, ts, t_treino + 1, t_teste, t_teste)
10:  resultados_gerais ← Adicionar(resultado_teste, resultados_gerais)
11: resultados_gerais ← Ordenar(resultados_gerais)
12: RETORNAR resultados_gerais

```

A função *treinar_ml* é utilizada para treinar os modelos de aprendizado de máquina. Nesta função, a série é separada em janelas e são realizados os ajustes para as diferentes combinações de parâmetros. Em seguida, verifica-se se o *smape* é o menor dentre todas as configurações passadas, e retorna-se o melhor modelo. Com o melhor modelo, é realizado o teste com *steps ahead* de 12 meses.

Algorithm 2 treinar_ml

```

1: function TREINAR_ML(ts, params, janelas)
2:   melhor_erro_global  $\leftarrow \infty$ 
3:   melhor_modelo  $\leftarrow$  NULL
4:   for janela em janelas do
5:     ts_janelas  $\leftarrow$  transformar_em_janelas(ts, janela)
6:     ts_projecao  $\leftarrow$  projecao_janelas(ts_janelas)
7:     for preproc em params.preprocess do
8:       modelo_treinado  $\leftarrow$  ajustar_diretamente(ts_projecao.input, ts_projecao.output)
9:       ajuste  $\leftarrow$  prever(modelo_treinado, ts_projecao.input)
10:      erro_smape  $\leftarrow$  avaliar_smape(ts_projecao.output, ajuste)
11:      if erro_smape < melhor_erro_global then
12:        melhor_erro_global  $\leftarrow$  erro_smape
13:        melhor_modelo  $\leftarrow$  modelo_treinado
14:   RETORNAR melhor_modelo

```

A função **testar_ml** tem como objetivo validar o desempenho do melhor modelo selecionado na função anterior, aplicando a predição a um período definido pelo **steps_ahead**. Para isso, ela organiza os dados de teste em janelas deslizantes e os projeta em amostras de entrada e saída, executa a previsão do **steps_ahead** e compara os resultados previstos com os valores reais da séri. Ao final, é calculada métricas de erro, como MSE, SMAPE e R^2 , inserindo esses indicadores em um dataframe para permitir a análise do modelo.

Algorithm 3 testar_ml

```

1: function TESTAR_ML(modelo, ts, t_pos, t_size, steps_ahead)
2:   test_data  $\leftarrow$  x[t_pos : t_pos + t_size - 1]
3:   xwt  $\leftarrow$  transformar_dados_teste_em_janelas(x[janela_relevante], obj.sw_size)
4:   xyt  $\leftarrow$  projetar_janelas_para_entrada_saida(xwt)
5:   predicao  $\leftarrow$  predict(obj.model, xyt.input[1:], steps_ahead=t_size)
6:   performance  $\leftarrow$  compute_performance(obj.model, test_data, predicao)
7:   dataframe_de_resultados  $\leftarrow$  Criar dataframe com as médias de MSE, SMAPE,  $R^2$ .
8:   RETORNAR dataframe_de_resultados e objeto_modelo_completo

```

Os modelos são testados com um conjunto amplo de hiperparâmetros para que, quando combinados na busca exaustiva, seja encontrada uma quantidade de configurações suficiente para avaliar a capacidade do modelo de prever a série temporal. Exceto pelo Auto Arima, há parâmetros em comum entre os modelos. Todos foram testados com um conjunto de janelas de **6, 12, 24, 36 e 48** meses, que representam variações semestral e anuais; os métodos de pré-processamento utilizados foram: **ts_norm_an**, **ts_norm_ean**, **ts_norm_gminmax**, **ts_norm_swminmax**, **ts_norm_diff**. Na tabela 2 constam os modelos utilizados e o parâmetros específicos de cada modelo. As notações a seguir e **seq(0.1, 0.2, 0.02)** referem-se a métodos

de geração de sequências numéricas. A expressão em colchetes com dois pontos (**[1:16]**) indica um intervalo de números inteiros com incremento unitário; por exemplo, [1:16] define que o modelo será testado com todos os valores inteiros de 1 a 16. Já a função **seq(início, fim, incremento)** permite criar sequências com maior precisão decimal: no caso de **seq(0.1, 0.2, 0.02)**, o parâmetro decay assume os valores 0.10, 0.12, ... , 0.20. Essas definições são fundamentais para delimitar o espaço de busca, garantindo que o algoritmo explore tanto variações discretas na arquitetura quanto ajustes finos em parâmetros de regularização.

Tabela 2: Hiperparâmetros dos modelos

modelo	configurações
mlp	input_size: NA; size = [1:16]; decay = seq(0.1, 0.2, 0.02); maxit = 1000;
elm	nhid = [1:18]; actfun = ['sig','relu','purelin'];
knn	k = [3:36];

Por limitações técnicas do pacote **tspredict**, o modelo Auto ARIMA foi implementado sem o componente de sazonalidade. A função **ts_integtune()** da biblioteca **TSPredit** realiza a validação cruzada com 10 folds no treinamento do modelo para a seleção de certos hiperparâmetros de cada modelo.

Após a execução da busca em grade, escolhe-se o modelo vencedor, com a melhor configuração e parâmetros e janela de input para o qual será criado o gráfico de comportamento.. O objetivo destes gráficos é analisar visualmente o comportamento do modelo à medida que os dados são acrescentados, verificando a qualidade e o que é esperado dos ajustes e das predições dentro do contexto do trabalho.

Capítulo 5

Resultados

Esta seção apresenta e compara os resultados obtidos na experimentação, conforme organizados na Tabela 3. O objetivo principal desta etapa é avaliar e contrapor o desempenho preditivo de diferentes abordagens de modelagem, abrangendo tanto métodos estatísticos clássicos quanto redes neurais artificiais, como Auto ARIMA, MLP, ELM e KNN. A partir dessa análise, busca-se identificar o modelo com a configuração que melhor captura o comportamento da série.

A métrica R^2 foi priorizada como critério de ranqueamento por representar a proporção da variância explicada pelo modelo, sendo adequada para avaliar previsões com foco em explicabilidade global [Chicco et al., 2021]. Para os gráficos utilizados, a linha listrada em azul indica o ajuste do modelo à série temporal, enquanto a linha em verde indica os valores previstos para os 12 meses seguintes. Os resultados sintetizados na tabela 3 mostram a melhor configuração dos modelos testados dentro do espaço de amostra das configurações.

Os gráficos das séries a seguir foram gerados para o modelo vencedor de cada tipo (mlp, knn, elm) posteriormente à fase de treinamento e teste dos modelos, com o intuito de representar visualmente o comportamento das previsões por meio de folds. Como o objetivo do estudo é a previsão anual de receitas de multas de trânsito, cada fold avança a série temporal em 12 observações (um ano), demonstrando a adaptação do modelo à medida que novos dados reais são inseridos. No canto superior esquerdo é mostrado o tipo do modelo e a janela de previsão. Abaixo mostram-se também as suas configurações de parâmetros, obtidas na etapa de Busca em Grade a largura da janela utilizada e o fold em que está. Considerando que a escolha da largura da janela de um modelo impacta diretamente em R^2 , cada modelo pode ter diferentes quantidades de folds e, consequentemente diferentes quantidades de folds.


Tendo como base a tabela 3 e a figura 5, o ARIMA apresenta ajustes bastante precisos, porém, defasados. A capacidade de explicativa deste modelo mostra uma concreta inferioridade em relação ao MLP e ELM. O seu resultado de R^2 negativo é compatível com um modelo que falha em capturar a variância da série original.

Para estes modelos testados, observa-se que o modelo MLP apresentou melhor desempenho

Tabela 3: Resultados obtidos na experimentação ranqueados em ordem crescente de R^2 .

modelo	R^2	SMAPE	MSE
mlp	60.26%	17.43%	$2,983 \times 10^{13}$
elm	33.83%	26.76%	$4,968 \times 10^{13}$
knn	0.55%	21.05%	$3,374 \times 10^{13}$
auto arima	-14.02%	36.11%	$8,561 \times 10^{13}$

para a métrica R^2 , apesar de precisar de uma janela menor para prever série. Embora nas figuras 6, 7 e 8, quando o modelo tem menores quantidades de dados de treinamento, a previsão se comporta de maneira destoante da série original, porém, no último fold (figura 9), a previsão apresenta um comportamento adequado, prevendo de forma satisfatória a média local da série original.

**Figura 5:** Previsão da receita no período de 12 meses com o modelo Auto ARIMA.




Figura 6: Previsão da receita no período de 12 meses com o modelo MLP - fold 1.




Figura 7: Previsão da receita no período de 12 meses com o modelo MLP - fold 2.




Figura 8: Previsão da receita no período de 12 meses com o modelo MLP - fold 3.




Figura 9: Previsão da receita no período de 12 meses com o modelo MLP - fold 4.




Figura 10: Previsão da receita no período de 12 meses com o modelo KNN - fold 1.




Figura 11: Previsão da receita no período de 12 meses com o modelo KNN - fold 2.




Figura 12: Previsão da receita no período de 12 meses com o modelo ELM - fold 1.




Figura 13: Previsão da receita no período de 12 meses com o modelo ELM - fold 2.




Figura 14: Previsão da receita no período de 12 meses com o modelo ELM - fold 3.




Figura 15: Previsão da receita no período de 12 meses com o modelo ELM - fold 4.

Capítulo 6

Conclusão

Tendo em vista o propósito do trabalho de verificar a possibilidade de um modelo de aprendizado de máquina que seja capaz de prever o período de um ano da série de multas de trânsito, conclui-se que modelos de aprendizado de máquina é consideravelmente eficaz que o convencionalmente utilizado, baseado nos trabalhos relacionados a esse mesmo escopo. No que diz respeito à agregação temporal, esta técnica mostra sua relevância na redução de outliers da série temporal. Considerando o contexto, de acordo com Rostami-Tabar et al. à medida que a série cresce, é possível que se tenha dados suficientes para reduzir esse horizonte de previsão, aumentando o desempenhos dos modelos.

A série de multas de trânsito mostrou um comportamento capaz de ser previsto para certos modelos e configurações. Apesar da baixa quantidade de dados históricos, o MLP apresentou desempenho muito satisfatório ao obter R^2 com 60.26% para a previsão de um ano. Dado esse resultado, conclui-se que modelos de aprendizado de máquina podem ser utilizados para prever receitas de multas de trânsito nesse período.

Este trabalho considerou a previsão da série temporal de multas de trânsito do período de janeiro de 2014 a dezembro de 2024. Não foi possível, portanto, apresentar os resultados junto ao ano de 2025. Acrescentar os dados históricos do ano de 2025 pode revelar detalhes importantes sobre os modelos apresentados. Sugere-se também que trabalhos futuros testem outros modelos de aprendizado de máquina, como os modelos aprendizado profundo.

Referências

- Box, G. E. P. and Jenkins, G. M. *Time Series Analysis: Forecasting and Control*. Holden-Day, San Francisco, CA, first edition, 1970.
- Chen, C., Twycross, J., and Garibaldi, J. M. A new accuracy measure based on bounded relative error for time series forecasting. *PLOS ONE*, 12(3):e0174202, 2017. <https://doi.org/10.1371/journal.pone.0174202>
- Chicco, D., Warrens, M. J., and Jurman, G. The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science*, 7:1 – 24, 2021. <https://doi.org/10.7717/PEERJ-CS.623>
- da Costa, W. P. Orçamento público: a importância do orçamento participativo na gestão pública. *Revista Controle: Doutrinas e artigos*, 15(2):210–234, 2017.
- Da Silva, A. M., Shiaku, A. C., Lopes, J. E. F., and Pereira, V. S. Orçamento Público, Como Prever as Receitas? In *Encontro de Gestão e Negócios*, pages 134–151, 2018.
- Deputados, C. d. *Constituição da República Federativa do Brasil: 67ª edição*. Edições Câmara, 2025.
- Gujarati, D. *Basic Econometrics*. McGraw-Hill, Boston, 2003.
- Hansun, S. A new approach of moving average method in time series analysis. In *2013 International Conference on New Media Studies, ConMedia 2013*, 2013. <https://doi.org/10.1109/conmedia.2013.6708545>
- Hyndman, R. J. and Athanasopoulos, G. *Forecasting: principles and practice*. OTexts, 2018.
- Hyndman, R. J. and Khandakar, Y. Automatic time series forecasting: The forecast package for R. *Journal of Statistical Software*, 27(3):1 – 22, 2008. <https://doi.org/10.18637/jss.v027.i03>
- Koutsoukas, A., Monaghan, K. J., Li, X., and Huan, J. Deep-learning: investigating deep neural networks hyper-parameters and comparison of performance to shallow methods for modeling bioactivity data. *Journal of cheminformatics*, 9(1):42, 2017.

- Lima Neto, N. Arrecadação com multas de trânsito no rio cresce 35 *O Globo*, 2025.
- Louzano, J. P. d. O., Abrantes, L. A., Ferreira, M. A. M., and Zuccolotto, R. Causalidade de Granger do índice de desenvolvimento socioeconômico na gestão fiscal dos municípios brasileiros. *Revista de Administração Pública*, 53:610–627, 2019. <https://doi.org/10.1590/0034-761220180139>
- Monica and Agrawal, P. A survey on hyperparameter optimization of machine learning models. In *2024 2nd International Conference on Disruptive Technologies (ICDT)*, pages 11–15, 2024. <https://doi.org/10.1109/ICDT61202.2024.10489732>
- Naibert, N. T. Orçamento público: metodologia alternativa para previsão de receitas municipais. Technical report, <https://hdl.handle.net/10438/31056>, 2021.
- Nascimento, M. d. N. S. and Boente, D. R. Fatores associados aos erros de previsão orçamentária da receita do setor público. *Administração Pública e Gestão Social*, 2022. <https://doi.org/10.21118/apgs.v14i2.12945>
- Ogasawara, E., Alexandrino, F., Gea, C., Santos, D., Salles, R., Birindiba, V., Pacheco, C., Bezerra, E., Pacitti, E., Porto, F., and Carvalho, D. tspredict: Time Series Prediction with Integrated Tuning, 2025a.
- Ogasawara, E., Castro, A., Salles, D., Lima, J., Tavares, L., Carvalho, D., Bezerra, E., and Coutinho, R. daltoolbox: Leveraging Experiment Lines to Data Analytics, 2025b.
- Ogasawara, E., Salles, R., Porto, F., and Pacitti, E. *Event Detection in Time Series*. Synthesis Lectures on Data Management. Springer Nature Switzerland, Cham, 1 edition, 2025c.
- PUCRJ. Puc previsão multas. <https://github.com/RJ-SMTR/puc-previsao-multas>, 2024.
- Ramamohan, V., Singhal, S., Raj Gupta, A., and Bolia, N. B. Discrete simulation optimization for tuning machine learning method hyperparameters. *Journal of Simulation*, 18(5):745–765, 2024.
- Rostami-Tabar, B., Babai, M. Z., Syntetos, A., and Ducq, Y. Demand forecasting by temporal aggregation. *Naval Research Logistics (NRL)*, 60(6):479–498, 2013. <https://doi.org/10.1002/nav.21546>

- Salles, R., Mattos, P., Iorgulescu, A.-M. D., Bezerra, E., Lima, L., and Ogasawara, E. Evaluating temporal aggregation for predicting the sea surface temperature of the Atlantic Ocean. *Ecological Informatics*, 36:94 – 105, 2016. <https://doi.org/10.1016/j.ecoinf.2016.10.004>
- Sato, R. C. Gerenciamento de doenças utilizando séries temporais com o modelo ARIMA. *einstein (São Paulo)*, 11:128–131, 2013. <https://doi.org/10.1590/S1679-45082013000100024>
- Secretaria Municipal de Transportes do Rio de Janeiro. Autuações de trânsito – base de dados abertos. Data.Rio – Portal de Dados Abertos da Cidade do Rio de Janeiro. Disponível via Google BigQuery, projeto `rj-smtr`, tabela `transito.autuacao`, 2025.
- Silvestrini, A. and Veredas, D. Temporal aggregation of univariate and multivariate time series models: a survey. *Journal of Economic Surveys*, 22(3):458–497, 2008.
- Speeden, E. A. and Perez, O. C. Fatores que impactam na qualidade do planejamento orçamentário dos municípios do estado de São Paulo. *Administração Pública e Gestão Social*, 2019. <https://doi.org/10.21118/apgs.v12i1.5517>
- Vrieze, S. I. Model selection and psychological theory: a discussion of the differences between the akaike information criterion (aic) and the bayesian information criterion (bic). *Psychological methods*, 17(2):228, 2012.
- Zellner, A. *Seasonal Analysis of Economic Time Series*. U.S. Department of Commerce, Bureau of the Census, 1978.